Relatório Final: Análise de Dados de Notícias Financeiras para Otimização de Investimentos

Nomes: Ademar Araújo Teisen

RA: 23182969-2

Curso: Engenharia de Software

Série: ESOFT6S - A

Disciplina: Banco de Dados Nosql

Instituição: UniCesumar

Data: 19/10/2025

Sumário

1. Introdução
2. Análise 1: Volatilidade Mensal por Índice
   - 2.1. Pergunta de Análise
   - 2.2. Metodologia e Query
   - 2.3. Resultados
   - 2.4. Análise e Insights
3. Análise 2: Impacto por Volume de Negociação
   - 3.1. Pergunta de Análise
   - 3.2. Metodologia e Query
   - 3.3. Resultados
   - 3.4. Análise e Insights
4. Análise 3: Resumo para Dashboard (Setores e Eventos)
   - 4.1. Pergunta de Análise
   - 4.2. Metodologia e Query
   - 4.3. Resultados
   - 4.4. Análise e Insights
5. Conclusão
6. Referências

---

1. Introdução

Este relatório apresenta os resultados de um projeto de engenharia de dados realizado para a consultoria de investimentos fictícia 'Alpha Investments'. O objetivo principal foi analisar um conjunto de dados de notícias financeiras para extrair insights sobre como diferentes eventos e o sentimento geral das notícias impactam os índices de mercado. A 'Alpha Investments' busca utilizar esses insights para aprimorar as recomendações fornecidas aos seus clientes, orientando estratégias de investimento mais eficientes.

O dataset utilizado foi o "Conjunto de dados de eventos de mercado de notícias financeiras para PNL 2025", obtido através da plataforma Kaggle. Este conjunto de dados contém informações sobre notícias financeiras, incluindo data, fonte, setor, sentimento associado, evento de mercado relacionado, índice de mercado impactado, variação percentual do índice e volume de negociação[4]. Alguns desafios preliminares identificados incluíram a necessidade de converter datas armazenadas como string e tratar valores ausentes (`null`) no campo de sentimento.

Para atender às necessidades do cliente, o projeto focou em responder às seguintes perguntas de análise[5]:

1. Qual foi a média e o desvio padrão da variação percentual do índice (`Index_Change_Percent`) para cada índice de mercado (`Market_Index`), agrupados por mês, durante o ano de 2025?
2. Como o volume de negociação (`Trading_Volume`) se correlaciona com a variação média do índice? Agrupar as notícias por faixas de volume (Baixo: 0-100, Médio: 100-300, Alto: 300+) e calcular a `Index_Change_Percent` média para cada faixa.
3. Para um resumo gerencial, quais são: (a) Os 5 principais setores (`Sector`) com maior frequência de sentimento 'Positivo' (`Sentiment`) registrado nas notícias? (b) Os 5 principais eventos de mercado (`Market_Event`) que apresentaram a maior média de variação absoluta nos índices (`Index_Change_Percent`)?

As seções seguintes detalham a metodologia, as queries MongoDB utilizadas, os resultados obtidos e a análise dos insights gerados para cada pergunta.

---

2. Análise 1: Volatilidade Mensal por Índice

2.1. Pergunta de Análise

"Qual foi a média e o desvio padrão da variação percentual do índice (`Index_Change_Percent`) para cada índice de mercado (`Market_Index`), agrupados por mês, durante o ano de 2025? (Análise temporal da volatilidade)."

2.2. Metodologia e Query

Para responder a esta pergunta, foi construído um pipeline de agregação no MongoDB. Primeiramente, o campo `Date` (string) foi convertido para o formato `Date` do MongoDB utilizando o operador `$dateFromString`, permitindo a extração do mês. Em seguida, filtramos (`$match`) documentos onde a conversão de data foi bem-sucedida e o campo

`Index_Change_Percent` não era nulo. O passo principal foi agrupar (`$group`) os dados pelo índice de mercado (`Market_Index`) e pelo mês extraído da data (`$month`). Dentro de cada grupo, calculamos a média (`$avg`) da variação percentual e o desvio padrão populacional (`$stdDevPop`) como medida de volatilidade. Finalmente, ordenamos (`$sort`) e projetamos (`$project`) os resultados para clareza.

```
db.events.aggregate([
  // Estágio 1: Converter a string de data para objeto Date
  // Necessário para extrair o mês corretamente
  {
    $addFields: {
      eventDate: {
        $dateFromString: {
          dateString: '$Date',
          format: '%Y-%m-%d' // Formato da data no JSON
        }
      }
    }
  },
  // Estágio 2: Filtrar documentos onde a data foi convertida com sucesso
e Index_Change_Percent existe
  {
     $match: {
       eventDate: { $ne: null }, // Garante que a conversão funcionou
       Index_Change_Percent: { $ne: null } // Garante que temos o valor
para calcular
     }
  },
  // Estágio 3: Agrupar por Índice de Mercado e Mês
  {
    $group: {
      _id: {
        marketIndex: '$Market_Index',
        month: { $month: '$eventDate' } // Extrai o mês (1-12)
      },
      // Calcula a média da variação percentual
      avgChangePercent: { $avg: '$Index_Change_Percent' },
      // Calcula o desvio padrão populacional da variação percentual
      stdDevChangePercent: { $stdDevPop: '$Index_Change_Percent' },
      // Contagem de notícias (opcional, mas útil)
      newsCount: { $sum: 1 }
    }
  },
  // Estágio 4: Ordenar para melhor visualização (opcional)
  {
    $sort: {
      '_id.marketIndex': 1, // Ordena por índice
      '_id.month': 1      // Ordena por mês
```

```
    }
  },
   // Estágio 5: Formatar a saída (opcional, para clareza)
  {
    $project: {
      _id: 0, // Remove o _id padrão
      MarketIndex: '$_id.marketIndex',
      Month: '$_id.month',
      AverageChangePercent: '$avgChangePercent',
      StdDevChangePercent: '$stdDevChangePercent',
      NewsCount: '$newsCount'
    }
  }
])
```

2.3. Resultados

A execução da query gerou dados agregados por índice e mês. Abaixo, um extrato dos resultados para os índices 'ASX 200', 'BSE Sensex' e 'CAC 40':

MarketIndex	Month	AverageChangePercent	StdDevChangePercent	NewsCount
ASX 200	2	1.623.333.333	1.980.756.309	15
ASX 200	3	4.665.217.391	2.325.562.314	23
ASX 200	4	-456	2.597.008.022	30
ASX 200	5	-3.924.242.424	3.005.898.273	33
ASX 200	6	-3.989.473.684	2.842.781.986	19
ASX 200	7	6.722.222.222	2.957.524.876	18
ASX 200	8	15.875	2.985.068.833	16
BSE Sensex	2	365	3.156.461.627	16
BSE Sensex	3	5.068.181.818	343.788.834	22
BSE Sensex	4	3.986.363.636	2.984.400.801	22
BSE Sensex	5	8.705.263.158	2.296.758.525	19
BSE Sensex	6	-6.451.612.903	2.849.122.727	31
BSE Sensex	7	-3.525	2.628.365.699	16
BSE Sensex	8	-55	3.190.918.102	6
CAC 40	2	-5.836.363.636	2.887.037.717	22
CAC 40	3	-7.105.263.158	241.087.644	19
CAC 40	4	7.842.105.263	2.711.706.233	19
CAC 40	5	1.685.714.286	2.565.936.728	21
CAC 40	6	4.370.588.235	2.864.040.266	34
CAC 40	7	-3.678.571.429	2.664.386.895	28

2.4. Análise e Insights

A análise dos resultados mensais permite à Alpha Investments identificar períodos de maior ou menor volatilidade para diferentes mercados. O Desvio Padrão (`StdDevChangePercent`) é um indicador direto dessa volatilidade.

- **Observação de Volatilidade:** Por exemplo, para o índice 'BSE Sensex', os meses de Março (`StdDev` = 3.438) e Agosto (`StdDev` = 3.191) apresentaram a maior volatilidade associada às notícias analisadas. Em contraste, Maio (`StdDev` = 2.297) foi o mês de menor volatilidade para este índice.
- **Tendência Média:** A `AverageChangePercent` indica a tendência média do impacto das notícias no mês. Para o 'ASX 200', observamos uma tendência média negativa nos meses de Abril, Maio e Junho, enquanto Fevereiro teve uma média positiva.
- **Recomendação para Alpha Investments:** A consultoria pode usar estes dados para ajustar suas recomendações sazonais. Em meses identificados com alta volatilidade (alto `StdDev`) para um determinado índice, pode ser prudente recomendar estratégias de hedge ou alertar os clientes sobre riscos elevados. Meses com médias consistentemente negativas ou positivas podem indicar vieses temporais no impacto das notícias que merecem investigação adicional. A contagem de notícias (`NewsCount`) também pode indicar meses com maior fluxo de informações relevantes para o mercado.

---

3. Análise 2: Impacto por Volume de Negociação

3.1. Pergunta de Análise

"Como o volume de negociação (`Trading_Volume`) se correlaciona com a variação média do índice? Agrupar as notícias por faixas de volume (Baixo: 0-100, Médio: 100-300, Alto: 300+) e calcular a `Index_Change_Percent` média para cada faixa."

3.2. Metodologia e Query

Utilizamos o estágio `$bucket` do MongoDB para agrupar os documentos diretamente em faixas pré-definidas de `Trading_Volume` . Antes disso, filtramos (`$match`) para garantir que os campos `Trading_Volume` e `Index_Change_Percent` existissem e fossem numéricos. Dentro de cada bucket (faixa de volume), calculamos a contagem de notícias (`$sum: 1`) e a média da variação percentual do índice (`$avg`). Um estágio `$project` final foi usado para renomear as faixas e apresentar os resultados de forma mais clara.

```
db.events.aggregate([
  // Estágio 1: Filtrar documentos que tenham os valores necessários
  {
    $match: {
      Trading_Volume: { $ne: null, $type: "double" }, // Garante que é um
número
```

```
      Index_Change_Percent: { $ne: null }
    }
  },
  // Estágio 2: Agrupar usando $bucket
  {
    $bucket: {
      groupBy: "$Trading_Volume", // Campo a ser agrupado
      boundaries: [ 0, 100, 300, Infinity ], // Limites das faixas (0-
100, 100-300, 300+)
      default: "Other", // Opcional: caso algum valor não se encaixe
      output: { // O que calcular para cada faixa (bucket)
        count: { $sum: 1 }, // Contar quantos documentos em cada faixa
        avgIndexChange: { $avg: "$Index_Change_Percent" } // Calcular a
média da variação
      }
    }
  },
   // Estágio 3: Formatar a saída (opcional)
  {
    $project: {
       _id: 0, // Remover o _id técnico
       VolumeRange: { // Renomear o _id do bucket para algo mais claro
          $switch: {
             branches: [
               { case: { $eq: [ "$_id", 0 ] }, then: "Low (0-100)" },
               { case: { $eq: [ "$_id", 100 ] }, then: "Medium (100-300)"
},
               { case: { $eq: [ "$_id", 300 ] }, then: "High (300+)" },
             ],
             default: "Unknown"
          }
       },
       NewsCount: "$count",
       AverageIndexChange: "$avgIndexChange"
    }
  }
])
```

3.3. Resultados

A agregação resultou na seguinte sumarização por faixa de volume de negociação:

VolumeRange	NewsCount	AverageIndexChange
Low (0-100)	560 46	-0.0163 47
Medium (100-300)	1150 48	-0.0015 49

High (300+)	1132 50	-0.0465 51

3.4. Análise e Insights

Os resultados indicam uma relação sutil entre o volume de negociação associado a uma notícia e o impacto médio no índice.

- **Impacto Negativo Sutil:** Todas as faixas de volume apresentaram uma variação média ligeiramente negativa, sugerindo que, em média, as notícias neste dataset tenderam a coincidir com pequenas quedas ou que o mercado tem um viés ligeiramente negativo nos dias de notícias.
- **Volume Médio Quase Neutro:** Notícias associadas a um volume médio de negociação (100-300) tiveram o impacto médio mais próximo de zero (-0.0015%).
- **Alto Volume e Maior Queda Média:** Curiosamente, notícias associadas ao maior volume de negociação (300+) coincidiram com a maior queda média (-0.0465%). Isso *não* necessariamente significa que alto volume *causa* quedas, mas pode indicar que eventos que geram grande movimentação no mercado (alto volume) neste dataset foram, em média, ligeiramente negativos, ou que notícias com impacto negativo tendem a gerar mais volume.
- **Recomendação para Alpha Investments:** A consultoria pode informar seus clientes que, embora a correlação não seja forte, notícias que geram altíssimo volume de negociação neste dataset estiveram associadas a um impacto médio ligeiramente mais negativo do que notícias de baixo ou médio volume. Isso pode ser um fator secundário a considerar ao avaliar o impacto potencial de notícias futuras com base no volume esperado. Monitorar o volume pode ser um indicador complementar do sentimento ou da reação do mercado.

---

4. Análise 3: Resumo para Dashboard (Setores e Eventos)

4.1. Pergunta de Análise

"Para um resumo gerencial, quais são: (a) Os 5 principais setores (`Sector`) com maior frequência de sentimento 'Positivo' (`Sentiment`) registrado nas notícias? (b) Os 5 principais eventos de mercado (`Market_Event`) que apresentaram a maior média de variação absoluta (positiva ou negativa) nos índices (`Index_Change_Percent`)?"

4.2. Metodologia e Query

Para gerar essas duas listas distintas em uma única consulta, utilizamos o estágio `$facet`.

- **Pipeline A (Sentimento Positivo por Setor):** Filtramos (`$match`) apenas as notícias com `Sentiment` igual a "Positive". Agrupamos (`$group`) por `Sector` contando a ocorrência de notícias positivas. Ordenamos (`$sort`) de forma descendente pela contagem e limitamos (`$limit`) aos 5 primeiros.
- **Pipeline B (Impacto Absoluto por Evento):** Filtramos (`$match`) notícias com `Index_Change_Percent` não nulo. Usamos `$addFields` com o operador `$abs` para calcular o valor absoluto da variação, tratando impactos positivos e negativos de forma

igual em termos de magnitude. Agrupamos (`$group`) por `Market_Event` calculando a média (`$avg`) desse valor absoluto. Ordenamos (`$sort`) pela maior média de impacto absoluto e limitamos (`$limit`) aos 5 primeiros.

```
db.events.aggregate([
  // Estágio 1: Usar $facet para rodar duas agregações independentes
  {
    $facet: {
      // Pipeline A: Top 5 Setores por Sentimento Positivo
      topSectorsPositiveSentiment: [
        { $match: { Sentiment: "Positive" } }, // Filtra apenas
notícias positivas
        { $group: { _id: "$Sector", countPositive: { $sum: 1 } } }, //
Agrupa por setor e conta
        { $sort: { countPositive: -1 } }, // Ordena pela contagem
        { $limit: 5 } // Pega os 5 primeiros
      ],
      // Pipeline B: Top 5 Eventos por Maior Impacto Médio (Absoluto)
      topEventsByAvgImpact: [
        { $match: { Index_Change_Percent: { $ne: null } } }, //
Garante que o valor existe
        {
          $addFields: {
            // Calcula o valor absoluto da mudança percentual
            absoluteChange: { $abs: "$Index_Change_Percent" }
          }
        },
        {
          $group: {
             _id: "$Market_Event",
             // Calcula a média do valor absoluto
             avgAbsoluteChange: { $avg: "$absoluteChange" }
          }
        },
        { $sort: { avgAbsoluteChange: -1 } }, // Ordena pela maior
média de impacto
        { $limit: 5 } // Pega os 5 primeiros
      ]
    }
  }
])
```

4.3. Resultados

A query `$facet` retornou um documento contendo duas listas:

JSON

```
{
  "topSectorsPositiveSentiment": [
```

```
    { "_id": "Agriculture", "countPositive": 67 },
    { "_id": "Transportation", "countPositive": 64 },
    { "_id": "Aerospace & Defense", "countPositive": 61 },
    { "_id": "Materials", "countPositive": 60 },
    { "_id": "Telecommunications", "countPositive": 60 }
  ],
  "topEventsByAvgImpact": [
    { "_id": "Inflation Data Release", "avgAbsoluteChange": 2.678
},
    { "_id": "Central Bank Meeting", "avgAbsoluteChange": 2.627 },
    { "_id": "Market Rally", "avgAbsoluteChange": 2.601 },
    { "_id": "Geopolitical Event", "avgAbsoluteChange": 2.599 },
    { "_id": "Currency Devaluation", "avgAbsoluteChange": 2.577 }
  ]
}
```


4.4. Análise e Insights

Este resumo fornece informações valiosas para um dashboard gerencial da Alpha Investments:

- **Sentimento Setorial:** Os setores de Agricultura, Transporte, Aeroespacial & Defesa, Materiais e Telecomunicações foram os que tiveram o maior número de notícias com sentimento explicitamente classificado como "Positivo" neste dataset. Isso pode indicar uma cobertura mais favorável ou um desempenho percebido como positivo para esses setores durante o período analisado. A Alpha Investments pode usar isso como ponto de partida para investigar se os fundamentos desses setores justificam o otimismo ou se há um viés na cobertura da mídia.
- **Eventos de Maior Impacto:** Os eventos relacionados à divulgação de dados de inflação, reuniões de bancos centrais, ralis de mercado, eventos geopolíticos e desvalorizações cambiais foram os que, em média, causaram as maiores movimentações (positivas ou negativas) nos índices de mercado. Isso confirma a alta sensibilidade do mercado a indicadores macroeconômicos e eventos de instabilidade.
- **Recomendação para Alpha Investments:** Priorizar a comunicação e análise em torno dos 5 principais eventos de mercado identificados, pois eles tendem a gerar maior volatilidade e impacto. Investigar os setores com maior contagem de notícias positivas para entender os drivers desse sentimento e avaliar oportunidades de investimento ou potenciais exageros do mercado.

---

5. Conclusão

Este projeto demonstrou a capacidade de utilizar o MongoDB e seu Aggregation Framework para extrair insights valiosos a partir de dados não estruturados de notícias financeiras. Através da análise, foi possível responder às três perguntas chave propostas pela 'Alpha Investments'.

Identificamos padrões de volatilidade mensal para diferentes índices de mercado, revelando meses de maior e menor risco percebido. Analisamos a relação entre o volume de negociação e o impacto médio das notícias, observando que volumes muito altos coincidiram com uma ligeira tendência negativa média. Por fim, identificamos os

setores com maior frequência de notícias positivas e os eventos de mercado que geram, em média, as maiores movimentações absolutas nos índices.

Esses insights permitem que a 'Alpha Investments' compreenda melhor a dinâmica do mercado em resposta a notícias, identifique períodos e eventos de maior risco/oportunidade e avalie o sentimento predominante associado a diferentes setores. Essas informações podem ser diretamente aplicadas para refinar modelos de recomendação, ajustar estratégias de alocação de ativos e melhorar a comunicação com os clientes sobre os fatores que influenciam seus investimentos. O uso de operadores como `$dateFromString`, `$stdDevPop`, `$bucket`, `$abs` e `$facet` foi fundamental para alcançar a profundidade de análise necessária.

---

6. Referências

- Puri, Pratyush. (2025). *Financial News & Market Events Dataset (2025)*. Kaggle. Obtido de: https://www.kaggle.com/datasets/pratyushpuri/financial-news-market-events-dataset-2025/data?select=financial_news_events.json [67]
